Data Mining

POLITEKNIK NEGERI JEMBER

Uji Dataset Analisis Sentimen pada Twitter

Revi Ardiano Ramadhan

Program ini bertujuan untuk mengecek algoritma yang cocok

polije.ac.id

Laporan ini merupakan dokumentasi kegiatan data mining

Algoritma TF-IDF + Logistic Reg.

20
26

Logistic regression menggunakan fungsi matematika bernama Sigmoid untuk mengubah angka input (hasil perkalian bobot dan vektor TF-IDF) menjadi probabilitas antara 0 dan 1.

- T**erm Frequency (TF)**: Mengukur frekuensi kata dalam satu dokumen. Logikanya: semakin sering kata muncul, semakin relevan kata tersebut untuk dokumen itu.
- **Inverse Document Frequency (IDF**): Mengurangi bobot kata-kata yang terlalu umum muncul di semua dokumen (seperti "dan", "yang", "the"). Logikanya: jika sebuah kata muncul di hampir semua dokumen, kata tersebut tidak memberikan informasi yang unik atau pembeda.

Klasifikasi Kategori

Model dilatih dengan meminimalkan Log Loss / Cross-Entropy Loss

setiap fitur (bobot TF-IDF tiap kata) dikalikan dengan koefisien w yang dipelajari model, menggunakan gradient descent — secara iteratif menyesuaikan bobot w agar prediksi probabilitas semaksimal mungkin sesuai label asli.

INSIGHT PENTING!

Ada 3 label yakni negatif, netral dan positif. Bigram seperti "happy birthday", "good morning" sangat kuat di kelas positif, sedangkan "feel sick", "miss you" dominan di negatif.

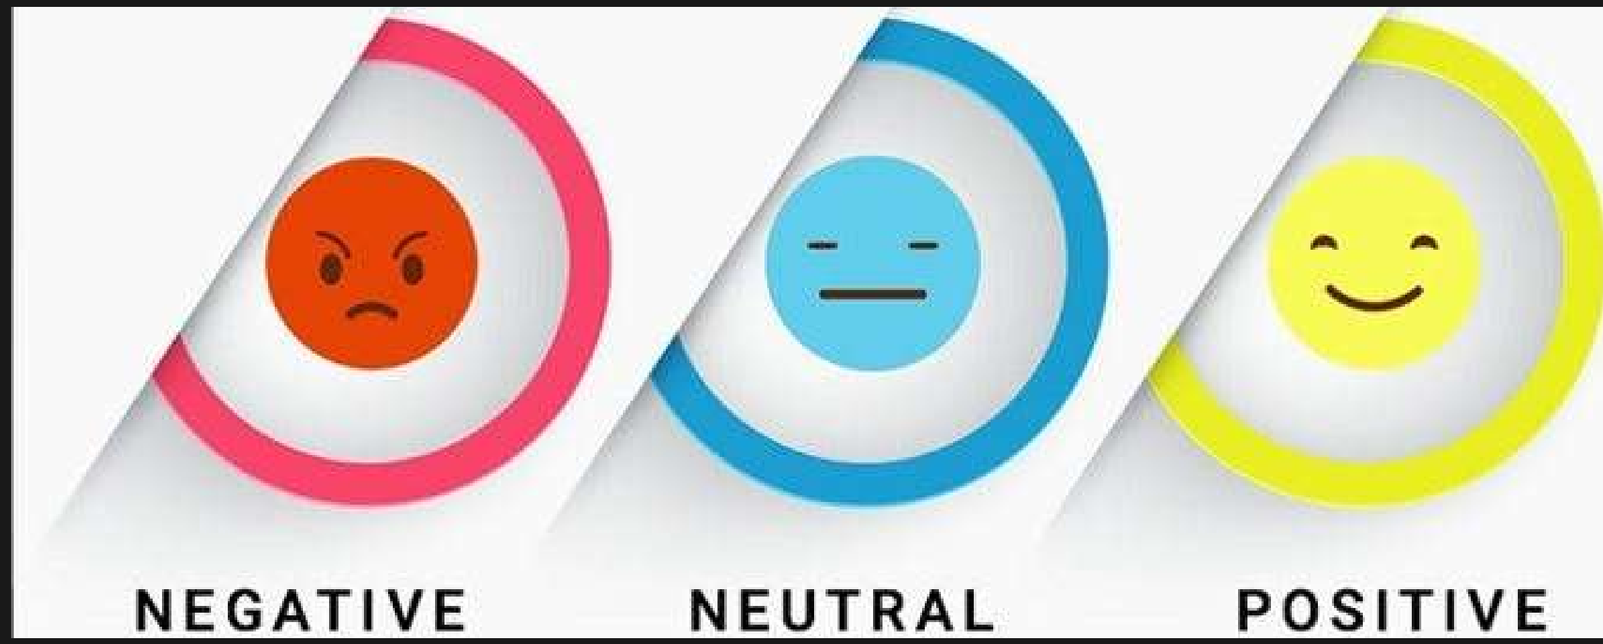

Data Mining

Bagaimana Klasifikasi Bekerja?

TF-IDF

Setiap tweet diubah menjadi vektor angka berbobot, Bigram (dua kata) seperti not good, very happy juga ditangkap, sehingga konteks sederhana bisa terbaca

Logistic Regression

Model mempelajari hubungan linear antara bobot kata dan probabilitas masing-masing kelas. Untuk setiap tweet, model menghitung skor untuk setiap sentimen, lalu memilih yang probabilitasnya tertinggi

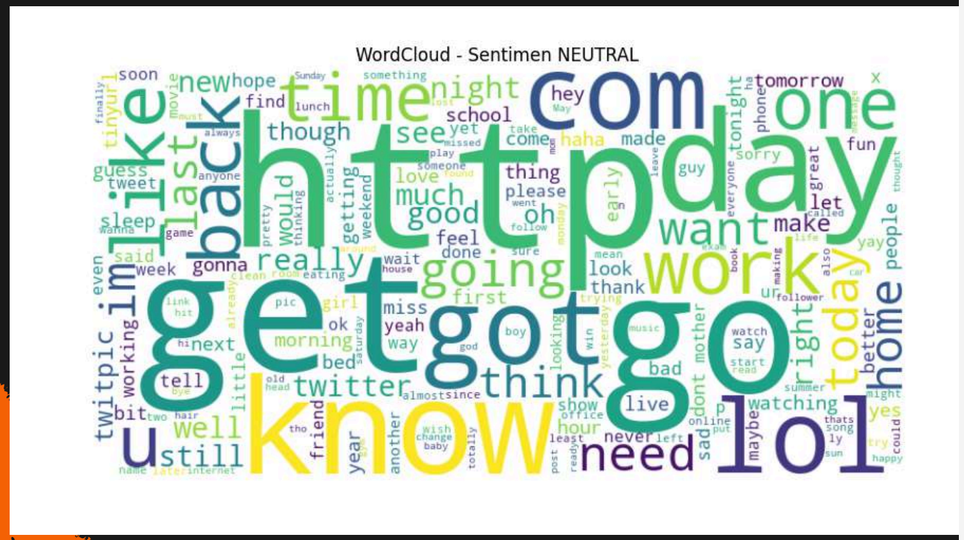

Kata-kata seperti "Today", "Time", dan "Going" menunjukkan bahwa tweet netral biasanya berisi laporan aktivitas sehari-hari atau sekadar membagikan status tentang apa yang sedang dilakukan (misal: "Sedang pergi bekerja", "Waktunya makan siang").

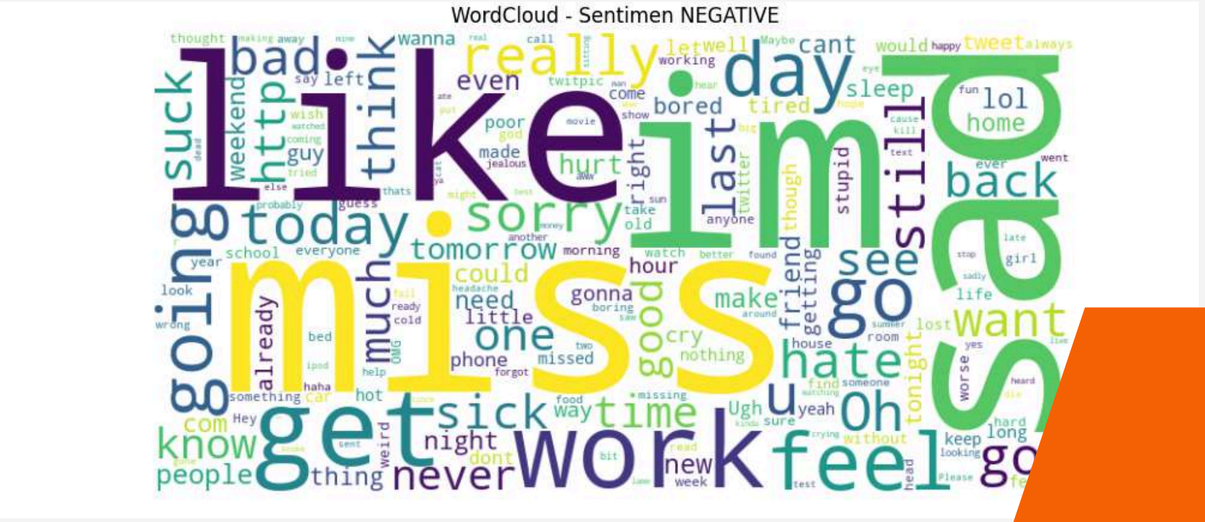

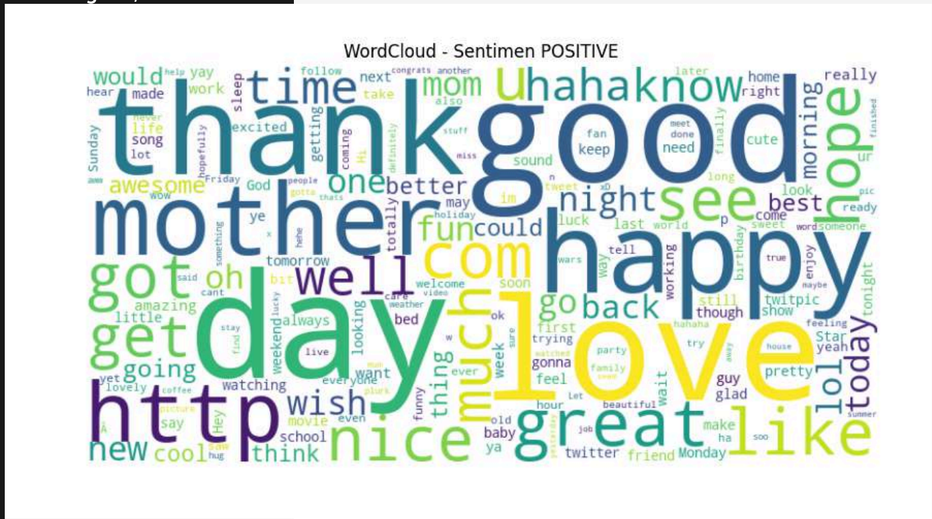

Penggunaan kata "Miss" (merindukan/kehilangan) dan "Sorry" (maaf) menunjukkan bahwa banyak sentimen negatif muncul dari rasa penyesalan atau kehilangan hubungan sosial. Kata-kata seperti "Work" dan "Sick" juga muncul, mengindikasikan keluhan terkait beban kerja atau kondisi kesehatanksanaan KKN tentu tidak lepas dari tantangan, seperti keterbatasan dana, waktu yang singkat, serta fasilitas museum yang terbatas.

Dataset Preview

textID	text	Land Area (Km²)	Density (P/Km²)
f87dea47db	Last session of the day http://twitpic.com/67ezh	6.528.600	600
96d74cb729	Shanghai is also really exciting (precisely -...)	274.000	1.050
eee518ae67	Recession hit Veronique Branquinho, she has	23.817.400	180
01082688c6	happy bday!	4.700	1.640
33987a8ee5	http://twitpic.com/4w75p - I like it!!	12.467.000	260

INSIGHT DATASET

Dataset memiliki 4.815 data dengan 9 fitur/kolom. Data utama berupa :

- Text (tweet / kalimat pendek)
- Data numerik tambahan (Land Area & Density)

Lalu, terdapat kombinasi dataset menggabungkan antara teks dan data wilayah.

Hasil Confussion Matrix

Model hanya salah menebak 43 teks Negatif sebagai Positif (dan sebaliknya, hanya 48 teks Positif sebagai Negatif).

Tidak ada satu kelas pun yang "hancur" performanya. Jumlah prediksi benar di tiap kategori (1100-1200) relatif merata, yang menandakan dataset kemungkinan besar cukup seimbang (balanced dataset).

Sentimen Positive adalah yang paling bisa untuk ditebak oleh model (1210 benar). Ini biasanya karena kata-kata positif (seperti "love", "happy") lebih spesifik dan jarang tumpang tindih dengan kata negatif.

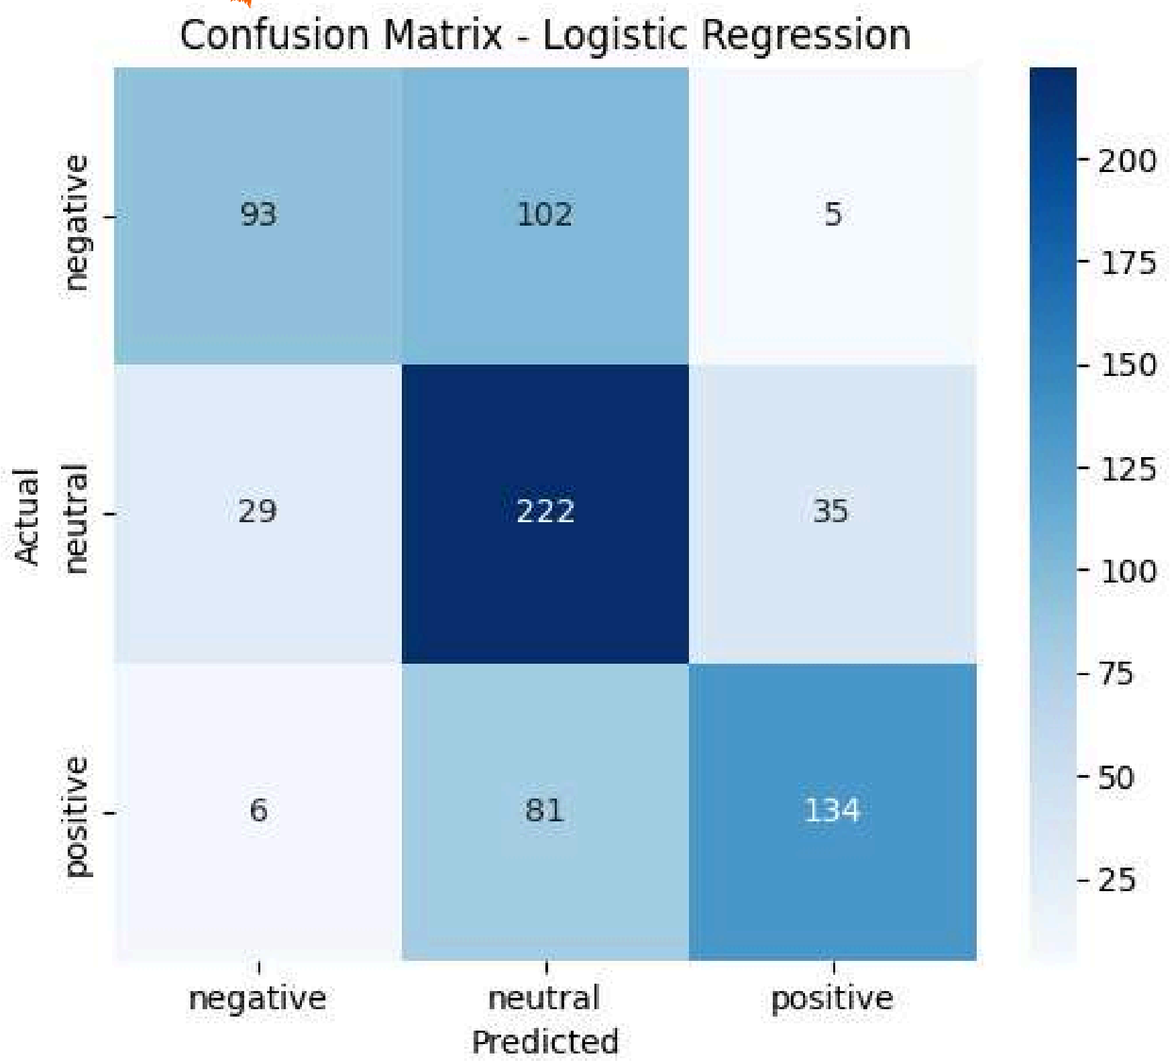

Politeknik Negeri Jember

Kesimpulan

Model Logistic Regression dengan fitur TF-IDF (max 5000 fitur, unigram+bigram) mencapai akurasi 63.51% pada data uji. Hasil cross-validation menunjukkan model stabil dan tidak overfitting.

2029

Model sebenernya tidak buruk, bisa dipakai sebagai baseline